

Modelos de regresión de series de tiempo.

N. Pérez-Medina

FING - UACH

19 de mayo de 2025



1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSML
- Valores ajustados
- Bondad de ajuste


3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos

4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación





1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSLM
- Valores ajustados
- Bondad de ajuste



3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos


4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación





Concepto central.



Sobre los coeficientes.

$$y_t = \beta_0 + \beta_1 x_t + \epsilon_t$$

- β_0 *Valor esperado de y cuando $x = 0$*
- β_1 *Cambio promedio en y por cada unidad de incremento en x*



Ejemplo 1

Contexto

Se analiza la relación entre el ***gasto en consumo personal*** y_t y el ***ingreso disponible personal*** x_t en Estados Unidos.



Ejemplo 1



Contexto

Se analiza la relación entre el ***gasto en consumo personal*** y_t y el ***ingreso disponible personal*** x_t en Estados Unidos.

Específicamente

En la base de datos utilizada, las dos variables están expresadas en variaciones porcentuales trimestrales. Es decir, *cada observación representa el porcentaje de cambio con respecto al trimestre anterior.*








Ingreso disponible personal y Gasto en consumo personal

```
us_change |>
  pivot_longer(c(Consumption, Income), names_to="Series") |>
  autoplot(value) +
  labs(y = "% change")
```





Ingreso disponible personal y Gasto en consumo personal








Diagrama de dispersión y línea ajustada


```
us_change |>
  ggplot(aes(x = Income, y = Consumption)) +
  labs(y = "Consumption (quarterly % change)",
       x = "Income (quarterly % change)") +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE)
```





Diagrama de dispersión y línea ajustada





Función TSLM()

```
us_change |>
  model(TSLM(Consumption ~ Income)) |>
  report()

#> Series: Consumption
#> Model: TSLM
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -2.5824 -0.2778  0.0186  0.3233  1.4223
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   0.5445     0.0540   10.08 < 2e-16 ***
#> Income        0.2718     0.0467    5.82 2.4e-08 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.591 on 196 degrees of freedom
#> Multiple R-squared:  0.147,    Adjusted R-squared:  0.143
#> F-statistic: 33.8 on 1 and 196 DF, p-value: 2.4e-08
```




Modelo estimado

$$y_t = 0,5445 + 0,2718x_t + \epsilon_t$$

$\beta_0 = 5445$ indica que, aun cuando no se observe un cambio en el **ingreso disponible personal** x_t , se espera un incremento promedio del 0.59 % en el **gasto en consumo personal** y_t





Definición

Cuando el modelo incluye dos o más variables predictoras, se denomina **Modelo de Regresión lineal múltiple**. La forma general de este modelo es:

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \epsilon_t$$

Donde:

- y_t *Variable pronóstico*
- $x_{1,t} + x_{2,t} + \cdots + x_{k,t}$ *Variables predictoras*
- $\beta_1 + \cdots + \beta_k$ *Coefficientes*






Ejemplo 2

Contexto

Se extiende el modelo de regresión utilizado previamente para predecir el ***gasto en consumo personal*** a partir de 2 variables predictoras:

- *Income*: variación porcentual del ingreso disponible personal.
- *Savings*: variación porcentual en el ahorro.
- *Unemployment*: cambio trimestral en la tasa de desempleo.






Producción industrial, ahorro personal y tasa de desempleo en EE. UU

```
us_change |>
  select(-Consumption, -Income) |>
  pivot_longer(-Quarter) |>
  ggplot(aes(Quarter, value, colour = name)) +
  geom_line() +
  facet_grid(name ~ ., scales = "free_y") +
  guides(colour = "none") +
  labs(y="% change")
```







Regresión lineal múltiple


Producción industrial, ahorro personal y tasa de desempleo en EE. UU





Regresión lineal múltiple

Matriz de gráficos de dispersión






Supuestos

¿Qué se supone que suponemos?

- 1 Supuesto general del modelo
- 2 Supuestos sobre los errores
- 3 Supuesto sobre las variables predictores





1- Supuesto general del modelo

Se *asume* que la relación entre la **variable de pronóstico** y las **variables predictoras** puede aproximarse mediante una **relación lineal**.






2- Supuestos sobre los errores

- **Media cero:**
- **No autocorrelación:**
- **Independencia respecto a los predictores:**






2- Supuestos sobre los errores

- **Media cero:** De lo contrario, los pronósticos estarán sesgados.
- **No autocorrelación:** Si hay autocorrelación, se pierde eficiencia en el pronóstico, ya que hay información no aprovechada.
- **Independencia respecto a los predictores:** Si los errores están correlacionados con las variables predictoras, se viola la suposición de que toda la información sistemática está en el modelo.







3- Supuesto sobre las variables predictoras

- Las variables x se tratan como **no aleatorias**.





1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSML
- Valores ajustados
- Bondad de ajuste

3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos

4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación



Principio de los Mínimos Cuadrados

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \epsilon_t$$





Principio de los Mínimos Cuadrados

$$\epsilon_t = y_t - (\beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t})$$







Principio de los Mínimos Cuadrados

$$\epsilon_t^2 = (y_t - (\beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t}))^2$$







Principio de los Mínimos Cuadrados

$$\sum_{t=1}^T \epsilon_t^2 = \sum_{t=1}^T (y_t - (\beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t}))^2$$






Principio de los Mínimos Cuadrados

$$\sum_{t=1}^T \epsilon_t^2 = \sum_{t=1}^T (y_t - (\beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t}))^2$$

El proceso de encontrar **los mejores estimadores de los coeficientes** se conoce como *ajustar el modelo a los datos o entrenar el modelo*.







Mínimos cuadrados con función TSLM

```
fit_consMR <- us_change |>
  model(tslm = TSLM(Consumption ~ Income + Production +
                    Unemployment + Savings))
report(fit_consMR)
```







Mínimos cuadrados con función TSLM

```
#> Series: Consumption
#> Model: TSLM
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -0.9055 -0.1582 -0.0361  0.1362  1.1547
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   0.25311    0.03447    7.34 5.7e-12 ***
#> Income         0.74058    0.04012   18.46 < 2e-16 ***
#> Production     0.04717    0.02314    2.04  0.043 *
#> Unemployment  -0.17469    0.09551   -1.83  0.069 .
#> Savings        -0.05289    0.00292  -18.09 < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.31 on 193 degrees of freedom
#> Multiple R-squared:  0.768    Adjusted R-squared:  0.763
```





Valor-t y Valor-p

Valor t



Mide cuán grande es el coeficiente estimado en relación con su error estándar.

Valor p

Indica la probabilidad de que el coeficiente observado se haya producido por azar.

Aunque *útiles* para **entender la relevancia de los predictores**, estos valores no son *cruciales* para la predicción futura de los datos.





Valores ajustados

¿Qué hacemos con lo que obtenemos?

Las predicciones¹ de y pueden obtenerse utilizando los **coeficientes estimados** en la ecuación de regresión y poniendo el término de error a cero.

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_{1,t} + \hat{\beta}_2 x_{2,t} + \cdots + \hat{\beta}_k x_{k,t}$$

¹No son pronósticos genuinos, son las predicciones para los mismos datos que se usaron para ajustar el modelo.




Valores ajustados y Valores reales

```
augment(fit_consMR) |>
  ggplot(aes(x = Quarter)) +
  geom_line(aes(y = Consumption, colour = "Data")) +
  geom_line(aes(y = .fitted, colour = "Fitted")) +
  labs(y = NULL,
       title = "Percent change in US consumption expenditure"
  ) +
  scale_colour_manual(values=c(Data="black",Fitted="#D55E00")) +
  guides(colour = guide_legend(title = NULL))
```



Valores ajustados y Valores reales



Percent change in US consumption expenditure



Valores ajustados vs. Valores reales

```
augment(fit_consMR) |>
  ggplot(aes(x = Consumption, y = .fitted)) +
  geom_point() +
  labs(
    y = "Fitted (predicted values)",
    x = "Data (actual values)",
    title = "Percent change in US consumption expenditure"
  ) +
  geom_abline(intercept = 0, slope = 1)
```







Valores ajustados

Valores ajustados vs. Valores reales

Percent change in US consumption expenditure







Valor de R^2

Una forma común de resumir qué tan bien ajusta un modelo de regresión lineal a los datos es calculado el **coeficiente de determinación**:

$$R^2 = \frac{\sum_{t=1}^T (y_t - \bar{y})^2}{\sum_{t=1}^T (y_t - \hat{y}_t)^2}$$






Bondad de ajuste

Observaciones del valor de R^2

- Refleja la **proporción de la variabilidad** en la variable dependiente y **que es explicada por el modelo de regresión**.
- Validar el rendimiento de pronóstico de un modelo utilizando datos de prueba **es mucho más confiable que medir R^2** sobre los datos de entrenamiento.





1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSML
- Valores ajustados
- Bondad de ajuste


3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos

4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación







Definición

Las diferencias entre los valores observados de y y los valores ajustados $\hat{y}$ son los **errores del conjunto de entrenamiento** o **residuos**, definidos como:

Residuos

$$\epsilon_t = y_t - \hat{y}_t$$







Observaciones

- Es necesario verificar los residuos para asegurarse de que los *supuestos* del modelo se hayan satisfecho.
- Se deben realizar una serie de gráficos para evaluar diferentes aspectos de los residuos y del modelo ajustado.






Para evaluar el modelo ajustado

- Histograma de residuos
- Función de autocorrelación de residuos
- *Conteo* de residuos

```
fit_consMR |> gg_tsresiduals( )
```





Para evaluar el modelo ajustado



Residuos vs. Predictores

Una forma rápida y sencilla de evaluar el modelo es examinar los **diagramas de dispersión de los residuos contra cada una de las variables predictoras**. Si estos diagramas muestran un patrón, entonces la relación podría ser no lineal y el modelo necesitaría ser modificado en consecuencia.








Residuos vs. Predictores

```
us_change |>
  left_join(residuals(fit_consMR), by = "Quarter") |>
  pivot_longer(Income:Unemployment,
               names_to = "regressor", values_to = "x") |>
  ggplot(aes(x = x, y = .resid)) +
  geom_point() +
  facet_wrap(. ~ regressor, scales = "free_x") +
  labs(y = "Residuals", x = "")
```



Residuos vs. Predictores






Residuos vs. Valores ajustados

Un gráfico de los residuos contra los valores ajustados también debería mostrar **ausencia de patrones**.

```
augment(fit_consMR) |>
  ggplot(aes(x = .fitted, y = .resid)) +
  geom_point() + labs(x = "Fitted", y = "Residuals")
```



Residuos vs. Valores ajustados



1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSLS
- Valores ajustados
- Bondad de ajuste

3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos

4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación



Definición

Es común que los datos de series de tiempo muestren tendencia. Una tendencia lineal puede modelarse utilizando simplemente $x_{1,t} = t$ como un predictor, con el modelo de regresión:

$$y_t = \beta_0 + \beta_1 t + \epsilon_t$$

Una variable de tendencia puede ser especificada en la función **TSLM()** usando el comando especial **trend()**.




Definición

Cuando un predictor es una **variable categórica** que toma solo dos valores, se puede manejar creando una *variable dummy* que:

- Toma el valor 1 correspondiente a *sí*
- Toma el valor 0 correspondiente a *no*

Una *variable dummy* también es conocida como *variable indicadora*.






Ejemplo de uso

Día	$d_{1,t}$	$d_{2,t}$	$d_{3,t}$	$d_{4,t}$	$d_{5,t}$	$d_{6,t}$
Lunes	1	0	0	0	0	0
Martes	0	1	0	0	0	0
Miércoles	0	0	1	0	0	0
Jueves	0	0	0	1	0	0
Viernes	0	0	0	0	1	0
Sábado	0	0	0	0	0	1
Domingo	0	0	0	0	0	0

Cuadro: Tabla de variables dummy para días de la semana





Trampa de la variable dummy

Se le conoce como ***trampa de la variable dummy*** a la situación en la que se incluye una variable dummy adicional para una categoría extra, lo que *genera un exceso de parámetros por estimar*.

Regla general

Usar **una variable dummy menos que el número de categorías**. Por ejemplo, con datos semanales, se deben usar seis variables dummy.




Ejemplo de producción trimestral de cerveza en Australia

La base de datos utilizada en este ejemplo contiene registros históricos de la producción de cerveza en Australia, desglosados por trimestre. Los datos incluyen:

- **Fecha:** Cada registro corresponde a un trimestre específico.
- **Cantidad de cerveza producida:** Medida en megalitros, que es una unidad de volumen que equivale a un millón de litros.







Ejemplo de producción trimestral de cerveza en Australia


```
recent_production <- aus_production |>
  filter(year(Quarter) >= 1992)
recent_production |>
  autoplot(Beer) +
  labs(y = "Megalitres",
       title = "Australian quarterly beer production")
```






Ejemplo de producción trimestral de cerveza en Australia

Australian quarterly beer production





Ejemplo de producción trimestral de cerveza en Australia

Queremos pronosticar el valor de la **producción futura de cerveza**. Podemos modelar estos datos utilizando un *modelo de regresión con una tendencia lineal y variables dummy trimestrales*:


$$y_t = \beta_0 + \beta_1 t + \beta_2 d_{2,t} + \beta_3 d_{3,t} + \beta_4 d_{4,t} + \epsilon_t$$



Ejemplo de producción trimestral de cerveza en Australia

```
fit_beer <- recent_production |>
  model(TSLM(Beer ~ trend() + season()))
report(fit_beer)
```





Ejemplo de producción trimestral de cerveza en Australia



```
#> Series: Beer
#> Model: TSML
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -42.90  -7.60   -0.46    7.99   21.79
#>
#> Coefficients:
#>                Estimate Std. Error t value Pr(>|t|)
#> (Intercept)   441.8004      3.7335  118.33 < 2e-16 ***
#> trend()        -0.3403      0.0666   -5.11 2.7e-06 ***
#> season()year2 -34.6597      3.9683   -8.73 9.1e-13 ***
#> season()year3 -17.8216      4.0225   -4.43 3.4e-05 ***
#> season()year4  72.7964      4.0230   18.09 < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 12.2 on 69 degrees of freedom
```



Ejemplo de producción trimestral de cerveza en Australia

- **Tendencia 1:** Existe una tendencia descendente promedio de -0.34 megalitros por trimestre.
- **Trimestre 2:** En promedio, la producción es 34.7 megalitros menor que en el primer trimestre.
- **Trimestre 3:** En promedio, la producción es 17.8 megalitros menor que en el primer trimestre.
- **Trimestre 4:** En promedio, la producción es 72.8 megalitros mayor que en el primer trimestre.








Modelo ajustado y Real

```
augment(fit_beer) |>
  ggplot(aes(x = Quarter)) +
  geom_line(aes(y = Beer, colour = "Data")) +
  geom_line(aes(y = .fitted, colour = "Fitted")) +
  scale_colour_manual(
    values = c(Data = "black", Fitted = "#D55E00")
  ) +
  labs(y = "Megalitres",
    title = "Australian quarterly beer production") +
  guides(colour = guide_legend(title = "Series"))
```

Modelo ajustado y Real






Modelo ajustado vs. Real

```
augment(fit_beer) |>
  ggplot(aes(x = Beer, y = .fitted,
             colour = factor(quarter(Quarter)))) +
  geom_point() +
  labs(y = "Fitted", x = "Actual values",
       title = "Australian quarterly beer production") +
  geom_abline(intercept = 0, slope = 1) +
  guides(colour = guide_legend(title = "Quarter"))
```



Modelo ajustado vs. Real



1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSLS
- Valores ajustados
- Bondad de ajuste


3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos

4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación





Modelar intervenciones

A menudo es necesario modelar intervenciones que pueden haber afectado la variable que estamos pronosticando. Por ejemplo:

- Actividades de competidores
- Gastos en publicidad
- Medidas laborales

entre otros, pueden tener un impacto significativo en los datos.



Modelar intervenciones

Cuando el efecto de la intervención dura solo un periodo, se utiliza una variable *spike*. Esta es una variable *dummy* que toma el valor de 1 en el **periodo de la intervención** y 0 en **los demás periodos**.

- **Ejemplo:** Si una campaña publicitaria ocurre durante un trimestre específico, la variable *spike* será 1 solo para ese trimestre y 0 para los demás.



Modelar intervenciones

Cuando el efecto de la intervención dura solo un periodo, se utiliza una variable *spike*. Esta es una variable *dummy* que toma el valor de 1 en el **periodo de la intervención** y 0 en **los demás periodos**.

- **Ejemplo:** Si una campaña publicitaria ocurre durante un trimestre específico, la variable *spike* será 1 solo para ese trimestre y 0 para los demás.

Equivalencia

Una variable *spike* es equivalente a una variable dummy para manejar un valor atípico.



Modelar intervenciones

Si una intervención provoca un **cambio de nivel** (es decir, el valor de la serie cambia de manera repentina y permanente desde el momento de la intervención), entonces utilizamos una variable *step*.

- Toma el valor de 0 antes de la intervención.
- Toma el valor de 1 después de la intervención²

²lo que indica que el efecto se mantiene de manera **permanente**.



Modelar intervenciones

Un tipo de **efecto permanente** es un cambio en la pendiente de la serie. En este caso, la intervención se maneja mediante una tendencia lineal a tramos (*piecewise linear trend*), lo que significa que la tendencia cambia en el momento de la intervención y se vuelve no lineal.

- **Características:** La tendencia se ajusta a una nueva pendiente a partir del momento de la intervención.



1 Modelo lineal

- Regresión lineal simple
- Regresión lineal múltiple
- Supuestos

2 Estimación de mínimos cuadrados

- Principio
- Estimación por TSLS
- Valores ajustados
- Bondad de ajuste

3 Evaluación del modelo de regresión

- Sobre los residuos
- Gráficos de residuos

4 Predictores útiles

- Tendencia (Trend)
- Variables dummy
- Aplicación





Por su atención

Gracias.

