

ANÁLISIS DE SERIES DE TIEMPO NO LINEALES

HOLGER KANTZ Y THOMAS SCHREIBER

*traducido por **natits***

Índice general

1. Temas básicos	5
1.1. Introducción: ¿por qué métodos no lineales?	5
1.2. Lecturas adicionales	8

Capítulo 1

Temas básicos

1.1. Introducción: ¿por qué métodos no lineales?

Probablemente estés leyendo este libro porque tienes una fuente interesante de datos y sospechas que no es lineal. O bien sabes positivamente que no es lineal porque tienes alguna idea de lo que está ocurriendo en la parte del mundo que estás observando, o bien sospechas que lo es porque has intentado un análisis de datos lineal y no quedaste satisfecho con sus resultados.

Los métodos lineales interpretan toda estructura regular en un conjunto de datos, como una frecuencia dominante, a través de correlaciones lineales (que se definirán en el Capítulo 2). Esto significa, en resumen, que la dinámica intrínseca del sistema está gobernada por el paradigma lineal según el cual causas pequeñas producen efectos pequeños. Dado que las ecuaciones lineales solo pueden dar lugar a soluciones que decaen (o crecen) exponencialmente o que oscilan periódicamente de manera amortiguada, todo comportamiento irregular del sistema debe atribuirse a algún tipo de entrada externa aleatoria. Ahora bien, la teoría del caos nos ha enseñado que la entrada aleatoria no es la única fuente posible de irregularidad en la salida de un sistema: los sistemas caóticos no lineales pueden generar datos muy irregulares con ecuaciones de movimiento puramente deterministas, de manera autónoma, es decir, sin términos dependientes del tiempo. Por supuesto, un sistema que posea tanto no linealidad como entradas aleatorias muy probablemente producirá datos irregulares también.

Aunque aún no hemos introducido las herramientas necesarias para hacer afirmaciones cuantitativas, veamos algunos ejemplos de conjuntos de datos reales. Ellos representan varios problemas diferentes de análisis de datos de los que se podría beneficiar un tratamiento con métodos no lineales, mientras que los métodos lineales resultarían inapropiados.

Ejemplo 1.1 (Datos de láser NMR)

En un experimento de laboratorio realizado en 1995 por Flepp, Simonet y Brun en el Departamento de Física de la Universidad de Zúrich, se operó un láser de Resonancia Magnética Nuclear bajo condiciones tales que la amplitud de la salida del láser (en radiofrecuencia) varía de manera irregular en el tiempo.

A partir de la configuración del experimento queda claro que el sistema es altamente no lineal y que el ruido de entrada aleatorio tiene una amplitud muy pequeña en comparación con la amplitud de la señal. Por lo tanto, no se asume que la irregularidad de la señal se deba únicamente al ruido de entrada. De hecho, ha sido posible modelar el sistema mediante un conjunto de ecuaciones diferenciales que no involucran ningún componente aleatorio en absoluto; véase Flepp *et al.* (1991). El Apéndice B.2 contiene más detalles sobre este conjunto de datos.

Los valores sucesivos de la señal parecen ser muy erráticos, como puede verse en la Fig. 1.1. No obstante, como veremos más adelante, es posible realizar predicciones bastante precisas de valores futuros de la señal utilizando un algoritmo de predicción no lineal. La Figura 1.2 muestra el error medio de predicción en función de qué tan lejos en el futuro se realizan los pronósticos. De manera intuitiva, mientras más lejos en el futuro se hagan las predicciones, mayor será la incertidumbre. Después de aproximadamente 35 pasos temporales, la predicción se vuelve peor que si simplemente se utilizara el valor medio como predicción (línea horizontal).

En horizontes de predicción cortos, el crecimiento del error de predicción puede aproximarse bien mediante una exponencial con un exponente de 0.3, lo cual se indica como línea discontinua. Usamos el método de predicción simple que se describirá en la Sección 4.2. Para comparación, también mostramos el resultado del mejor predictor *lineal* que pudimos ajustar a los datos (cruces). Observamos que la capacidad de predicción debida a las correlaciones lineales en los datos es mucho más débil que la debida a la estructura determinista, en particular para horizontes de predicción cortos. La predictibilidad de la señal puede considerarse una firma de la naturaleza determinista del sistema. Véase la Sección 2.5 para detalles sobre el método de predicción lineal utilizado.

La estructura no lineal que conduce a la predictibilidad a corto plazo en este conjunto de datos no es evidente en una representación como la de la Fig. 1.1. Sin embargo, podemos hacerla visible graficando cada punto de datos contra su predecesor, como se hace en la Fig. 1.3. A esta gráfica se le denomina *retrato de fases*. Esta representación es una aplicación particularmente simple de la *incrustación con retardo temporal*, una herramienta básica que se usa con frecuencia en el análisis de series temporales no lineales. Este concepto será introducido formalmente en la Sección 3.2. En el presente caso, solo necesitamos una representación de los datos que sea imprimible en dos dimensiones.

Ejemplo 1.2 (Frecuencia respiratoria humana)

Uno de los conjuntos de datos utilizados para la competencia de series temporales del Instituto Santa Fe en 1991–92 WeigendGershenfeld1993 fue proporcionado por A. Goldberger del Beth Israel Hospital en Boston Rigney1993; véase también el Apéndice B.5. De entre varios canales seleccionamos un registro de 16 minutos del flujo de aire a través de la nariz de un sujeto humano. Un gráfico de este segmento de datos se muestra en la Fig. 1.4.

En este caso se sabe muy poco sobre el origen de las fluctuaciones de la frecuencia respiratoria. El único indicio de que el comportamiento no lineal desempeña un papel proviene de los propios datos: la señal no es compatible con el supuesto de que haya sido generada por un proceso aleatorio gaussiano con solo correlaciones lineales (posiblemente distorsionado por una función de medición no lineal). Mostramos esto creando un conjunto de datos artificial que tiene exactamente las mismas propiedades *lineales*, pero sin ningún determinismo adicional incorporado. Este conjunto de datos consiste en números aleatorios que han sido reescalados para que la distribución de los valores coincida con la del original (por lo tanto, la media y la varianza también son idénticas) y filtrados de modo que el espectro de potencias sea el mismo. (Cómo se hace esto, y otros aspectos adicionales, se discuten en el Capítulo 4 y la Sección 7.1). Si los datos medidos se describieran adecuadamente mediante un proceso lineal, no deberíamos encontrar diferencias significativas respecto a los artificiales.

Usemos nuevamente una *incrustación con retardo temporal* para visualizar y comparar las series temporales original y artificial. Simplemente graficamos cada valor de la serie frente al valor tomado un tiempo de retardo t antes. Encontramos que los dos *retratos de fases* resultantes se ven cualitativamente diferentes. Parte de la estructura presente en los datos originales (Fig. 1.5, panel izquierdo) no se reproduce en la serie artificial (Fig. 1.5, panel derecho). Dado que ambas series tienen las mismas propiedades lineales, la diferencia probablemente se deba a la no linealidad en el sistema. Más significativamente aún, el conjunto de datos original es estadísticamente asimétrico bajo inversión temporal, lo cual se refleja en el hecho de que la Fig. 1.5, panel izquierdo, es no simétrica bajo reflexión respecto a la diagonal. Esta observación hace muy poco probable que la serie de datos represente una oscilación armónica ruidosa.

Ejemplo 1.3 (Datos de cuerda vibrante)

Nick Tufillaro y Timothy Molteno, en el Departamento de Física de la Universidad de Otago, Dunedin, Nueva Zelanda, proporcionaron un par de series temporales (véase el Apéndice B.3) de una cuerda vibrante en un campo magnético.

La envolvente de la elongación del alambre experimenta oscilaciones que pueden ser caóticas, dependiendo de los parámetros elegidos. Uno de estos conjuntos de datos está dominado por un ciclo de período cinco, lo que significa que después de cada quinta oscilación el registro se (aproximadamente) repite. En la Fig. 1.6 mostramos las elongaciones x e y registradas simultáneamente. Trazamos una línea continua a lo largo de las primeras 1000 mediciones y colocamos un punto en cada una de las siguientes 4000. Observamos que el ciclo de período cinco no se mantiene perfecto durante el intervalo de medición. Esto se hace más evidente al graficar un punto por cada ciclo contra el número de ciclos. (Estos puntos se obtienen de manera sistemática mediante la llamada *sección de Poincaré*; véase la Sección 3.5.) En la Fig. 1.7 se aprecia que el ciclo de período cinco se interrumpe ocasionalmente. Una explicación natural podría ser la presencia de influencias externas sobre el equipo que provocan que el sistema abandone el estado periódico. Sin embargo, una explicación mucho más apropiada de este conjunto de datos se da en el Ejemplo 8.3 de la Sección 8.4. Los episodios irregulares se deben en realidad a la *intermitencia*, un fenómeno típico encontrado en sistemas dinámicos no lineales.

Ejemplo 1.4 (Electrocardiograma fetal)

Consideremos el problema de procesar una señal para extraer el diminuto componente del electrocardiograma fetal a partir de los (pequeños) potenciales eléctricos en el abdomen de una mujer embarazada (trazo superior en la Fig. 1.8). La señal fetal, más rápida y más pequeña, no puede distinguirse con técnicas lineales clásicas porque tanto los electrocardiogramas maternos como los fetales tienen espectros de potencia de banda ancha. Sin embargo, utilizando una técnica no lineal de proyección en el espacio de fases, que originalmente fue desarrollada para la reducción de ruido en datos caóticos (Sección 10.3.2), es posible realizar la separación de manera

automática. El trazo inferior en la Fig. 1.8 muestra el componente fetal extraído. Se ofrecen más explicaciones en la Sección 10.4. Nótese que no necesitamos suponer (ni en realidad esperamos) que el corazón sea un sistema caótico determinista.

Existe una amplia gama de cuestiones que debemos abordar al hablar del análisis de series temporales no lineales. ¿Cómo podemos obtener los resultados más precisos y significativos para un conjunto de datos limpio y claramente determinista, como el del primer ejemplo? ¿Qué modificaciones son necesarias si el caso es menos claro? ¿Qué puede hacerse si, como en el ejemplo de la frecuencia respiratoria, todo lo que tenemos son indicios de que los datos no se describen adecuadamente mediante un modelo lineal con entradas gaussianas? Dependiendo del conjunto de datos y de la tarea de análisis que tengamos en mente, elegiremos diferentes enfoques. No obstante, hay una serie de ideas generales con las que conviene familiarizarse, independientemente del aspecto de los datos. Los conceptos más importantes para analizar datos complejos se presentarán en la Primera Parte de este libro. Los temas que son más teóricos, requieren datos de mayor calidad o tienen un interés más especializado se tratarán en la Segunda Parte.

Obviamente, en un campo tan diverso como el análisis de series temporales no lineales, cualquier selección de temas para un solo volumen debe ser incompleta. Sería ingenuo afirmar que todas las elecciones que hemos hecho se basan exclusivamente en criterios objetivos. Existe un fuerte sesgo hacia métodos que hemos encontrado conceptualmente interesantes o útiles en el trabajo práctico, o ambos. Qué métodos resulten más útiles depende del tipo de datos a analizar y, por tanto, parte de nuestro sesgo ha sido determinado por nuestros contactos con grupos experimentales. Finalmente, no somos excepción a la regla de que la gente prefiere los métodos en los que ha estado involucrada en su desarrollo.

Aunque creemos que algunos enfoques presentados en la literatura son efectivamente inútiles para el trabajo científico (como determinar exponentes de Lyapunov a partir de tan solo 16 puntos de datos), queremos enfatizar que otros métodos que mencionamos solo brevemente o no mencionamos en absoluto, pueden ser muy útiles para un problema concreto de series temporales. A continuación listamos algunas omisiones importantes (aparte de las que fueron dejadas de lado por ignorancia nuestra). Generalizaciones no lineales de los modelos ARMA y otros métodos populares entre los estadísticos se presentan en Tong (1990). Generalizando la función usual de autocorrelación de dos puntos se llega al *bispectrum*. Este y modelos de series temporales relacionados se discuten en Subba Rao & Gabr (1984). Dentro de la teoría de sistemas dinámicos, el análisis de órbitas periódicas inestables juega un papel importante. Por un lado, las órbitas periódicas son importantes para el estudio de la topología de un atractor. Se han obtenido resultados muy interesantes sobre la estructura plantilla, números de enlace, etc., pero el enfoque se limita a aquellos atractores de dimensión dos o mayor que pueden ser embebidos en un espacio de fases tridimensional. (Las variedades unidimensionales, es decir, trayectorias de sistemas dinámicos, no forman nudos en más de tres dimensiones). Remitimos al lector interesado a Tufillaro *et al.* (1992). Por otro lado, las expansiones de órbitas periódicas constituyen una manera poderosa de calcular cantidades características que se definen como promedios sobre la medida natural, tales como dimensiones, entropías y exponentes de Lyapunov.

En el caso de que un sistema sea *hiperbólico*, es decir, que las direcciones de expansión y contracción no sean tangentes entre sí en ningún punto, se pueden derivar expresiones con convergencia exponencial para tales cantidades. Sin embargo, cuando la hiperbolicidad falta (el caso genérico), es necesario un número muy grande de órbitas periódicas para las expansiones de ciclo. Hasta ahora no se ha demostrado que este tipo de análisis sea factible con datos experimentales de series temporales. La teoría se explica en Artuso *et al.* (1990) y en *The Webbook* Cvitanovic2001.

Después de una breve revisión de los conceptos básicos del análisis lineal de series temporales en el Capítulo 2, se introducirán las ideas más fundamentales del enfoque de la dinámica no lineal en los capítulos sobre el espacio de fases (Capítulo 3) y sobre predictibilidad (Capítulo 4). Estos dos capítulos son esenciales para la comprensión del resto del texto; de hecho, el concepto de una representación en espacio de fases, en lugar de una en el dominio del tiempo o de la frecuencia, es la característica distintiva del análisis de series temporales dinámicas no lineales. Otro concepto fundamental de la dinámica no lineal es la sensibilidad de los sistemas caóticos a los cambios en las condiciones iniciales, lo cual se discute en el capítulo sobre inestabilidad dinámica y el exponente de Lyapunov (Capítulo 5). Para que un sistema disipativo sea simultáneamente acotado e inestable, su trayectoria debe residir en un conjunto con propiedades geométricas inusuales. El estudio de cómo se investigan estas series temporales se aborda en el capítulo sobre la geometría de atractores y dimensiones fractales (Capítulo 6). Cada uno de estos dos últimos capítulos contiene los fundamentos de su tema, mientras que material adicional se presentará más adelante en el Capítulo 11. Relajaremos el requisito de determinismo en el Capítulo 7 (y más tarde en el Capítulo 12). Propondremos ideas generales para inspeccionar y estudiar datos complejos, incluyendo enfoques visuales y simbólicos. Además, estableceremos métodos estadísticos para caracterizar datos que carecen de evidencia sólida de determinismo, como el escalamiento o la autosimilitud. Finalmente, situaremos nuestras consideraciones dentro del contexto más amplio de la teoría de sistemas dinámicos no lineales en el Capítulo 8.

La segunda parte del libro contendrá material avanzado que puede ser de interés una vez que uno de los algoritmos básicos haya sido aplicado con éxito; obviamente no tiene sentido estimar todo el espectro de exponentes de Lyapunov si ni siquiera el mayor de ellos ha sido determinado de manera confiable. Como regla general, refiérase a la Primera Parte para obtener resultados iniciales. Después, consulte la Segunda Parte para obtener resultados *óptimos*. Esta regla se aplica a las incrustaciones (Capítulo 9), al tratamiento de ruido (Capítulo 10), así como al modelado y predicción (Capítulo 12). Allí se incluyen métodos para tratar procesos no lineales con forzamiento estocástico. Un nivel matemático avanzado es necesario para el estudio de cantidades invariantes como espectros de Lyapunov y dimensiones generalizadas (Capítulo 11). Los avances recientes en el tratamiento de señales no estacionarias se presentan en el Capítulo 13. También se incluirá una breve descripción de la sincronización caótica en el Capítulo 14.

El control del caos es un campo enorme por sí mismo, pero dado que está estrechamente relacionado con el análisis de series temporales, se discutirá para concluir el texto en el Capítulo 15.

A lo largo del texto haremos referencia a implementaciones específicas de los métodos discutidos, que están incluidas en el paquete de software TISEAN.¹ El paquete TISEAN contiene una gran cantidad de rutinas, algunas de las cuales son implementaciones de técnicas estándar o incluidas por conveniencia (análisis espectral, números aleatorios, etc.), y no se discutirán más aquí. Nos centraremos en aquellas rutinas que implementan ideas esenciales del análisis de series temporales no lineales. Para más información, véase la documentación distribuida con el software.

El análisis de series temporales no lineales no está tan bien establecido ni es tan comprendido como su contraparte lineal. Aunque haremos todo lo posible por explicar las perspectivas y limitaciones de los métodos que introduciremos, será necesario familiarizarse con los algoritmos mediante el uso de datos artificiales donde se conozcan los resultados correctos. Aunque en los ejemplos hemos utilizado casi exclusivamente datos experimentales para ilustrar los conceptos discutidos en el texto, introduciremos varios modelos numéricos en los ejercicios. Invitamos al lector a resolver algunos de los problemas y a utilizar los datos artificiales antes de analizar datos medidos. Es una mala idea aplicar algoritmos poco familiares directamente a datos con propiedades desconocidas; es mejor practicar primero con datos que tengan propiedades conocidas, como el número de puntos de datos y la tasa de muestreo, el número de grados de libertad, la cantidad y naturaleza del ruido, etc. Para dar una idea de modelos populares, introduciremos el mapa logístico (Ejercicio 2.2), el mapa de Hénon (Ejercicio 3.1), el mapa de Ikeda (Ejercicio 6.3), un mapa tridimensional de Baier y Klein (Ejercicio 5.1), las ecuaciones de Lorenz (Ejercicio 3.2) y la ecuación diferencial retardada de Mackey–Glass (Ejercicio 7.2). Diversos modelos de ruido pueden considerarse para comparación, incluyendo el *promedio móvil* (Ejercicio 2.1) y el *movimiento browniano* (Ejercicio 5.3). Estos se utilizan únicamente como referencias en los ejercicios donde se introducen los métodos.

1.2. Lecturas adicionales

Evidentemente, cualquiera que desee aprovechar los métodos de series temporales basados en la teoría del caos mejorará su comprensión de los resultados aprendiendo más sobre dicha teoría. Existe un pequeño y recomendable libro acerca del azar y el caos escrito por Ruelle (1991). Una introducción accesible y sin demasiada carga matemática es el libro de Kaplan & Glass (1995). Otros textos sobre el tema incluyen a Bergé *et al.* (1986), Schuster (1988) y Ott (1993). Una presentación muy clara es la de Alligood *et al.* (1997). Material más avanzado se encuentra en Eckmann & Ruelle (1985) y en Katok & Hasselblatt (1996). Muchos artículos relevantes para los aspectos prácticos del caos se reproducen en Ott *et al.* (1994), complementados con una introducción general. Los aspectos teóricos de la dinámica caótica relevantes para el análisis de series temporales se discuten en Ruelle (1989).

Existen varios libros que cubren el análisis de series temporales caóticas, cada uno con un énfasis distinto. Abarbanel (1996) discute aspectos del análisis de series temporales con métodos de la teoría del caos, con un énfasis particular en el trabajo de su grupo sobre técnicas de vecinos más cercanos. El pequeño volumen de Diks (1999) se centra en varios aspectos particulares, incluyendo el efecto del ruido en datos caóticos, los cuales se discuten de manera bastante detallada. También hay monografías vinculadas a situaciones experimentales específicas, pero que contienen material de mayor interés general: Pawelzik (1991), Buzug (1994) (ambos en alemán), Tufillaro *et al.* (1992) y Galka (2000). Muchos artículos interesantes sobre métodos no lineales en series temporales pueden encontrarse en los siguientes volúmenes de actas de conferencias: Mayer-Kress (1986), Casdagli & Eubank (1992), Drazin & King (1992) y Gershenfeld & Weigend (1993). Artículos relevantes sobre dinámica no lineal y fisiología en particular se encuentran en Bélair *et al.* (1995). Revisiones importantes, cada una con puntos de vista algo diferentes, se hallan en Grassberger *et al.* (1991), Casdagli *et al.* (1991), Abarbanel *et al.* (1993), Gershenfeld & Weigend (1993) y Schreiber (1999). El paquete de software TISEAN está acompañado por un artículo de Hegger *et al.* (1999), que también puede usarse como una visión general de los métodos de series temporales.

¹Información de contexto sobre la implementación y sugerencias para el uso de los programas se ofrecen en el Apéndice A.

Para un estadístico interesado en la visión de las series temporales no lineales, véanse los libros de Priestley (1988) o de Tong (1990). Además, ha habido una serie de talleres en los que especialistas de diferentes campos se reúnen. Las actas de estos encuentros también contienen valiosos artículos de referencia.